

Politechnika Gdańska
Wydział Elektroniki, Telekomunikacji i Informatyki
Katedra Systemów Multimedialnych

Realizacja Projektu Informatycznego
Projekt Grupowy

Scrum: Backlog sprintu

Temat projektu: Wykrywanie jaskry z użyciem inteligentnej analizy obrazów dna oka

Członkowie zespołu (388):

Martyna Borkowska (kierownik), Karolina Glaza, Mateusz Dobry, Agnieszka Pawłowska, Amila Amarasekara, Antoni Naczke

Opiekun: prof. dr hab. inż. Andrzej Czyżewski

Data: 26 kwietnia 2026

Sprint: nr 5 (22.04.2026 - 05.05.2026)

Gdańsk, 2026

1 O projekcie i produkcji

Projekt skupia się na stworzeniu zintegrowanego systemu do wczesnego wykrywania jaskry. Rozwiązanie to wykorzystuje zaawansowane algorytmy sztucznej inteligencji (YOLO + UNet++) do analizy zdjęć dna oka pod kątem współczynnika Cup-to-Disc Ratio (CDR). System składa się z aplikacji mobilnej iOS, backendu w chmurze Azure oraz specjalistycznej nakładki na aparat smartfona.

2 Oszacowanie rozmiaru backlogu produktu

Rozmiar elementów backlogu został określony podczas wspólnej sesji całego zespołu przy użyciu techniki Planning Poker. Proces ten zrealizowano w formie zdalnej, a do estymacji wykorzystano ciąg Fibonacciego (1, 2, 3, 5, 8). Taka skala pozwoliła na odpowiednie odzwierciedlenie niepewności oraz złożoności technicznej związanej z trenowaniem modeli AI oraz integracją frontendu w Swifcie z chmurą Azure.

Podczas gry poszczególne historie użytkowników były krótko omawiane przez osobę odpowiedzialną za dany obszar (np. detekcja ROI za pomocą YOLO). W przypadku rozbieżności w rzucanych wartościach (np. gdy jedna osoba dawała 2, a inna 5 Story Points), członkowie zespołu krótko argumentowali swoje stanowisko, aż do osiągnięcia zgodności. Dzięki temu każda z osób w zespole miała jasność co do zakresu prac, co wyeliminowało ukryte ryzyka architektoniczne.

2.1 Dokumentacja przebiegu gry Planning Poker

Proces estymacji zadania „Retrain UNET++ model on expanded dataset” wymagał czterech rund dyskusji, aby zespół osiągnął pełną zgodę co do złożoności prac i rozwiązał wszelkie wątpliwości.

Runda 1

W pierwszej turze głosy były mocno podzielone - padły wyceny od 2 do 8 Story Points. Karolina oceniła zadanie najniżej (2 SP), podczas gdy Amile dostrzegł największe ryzyko i wskazał aż 8 SP. Pozostali członkowie zespołu wybrali 3 SP (Agnieszka, Mateusz) oraz 5 SP (Antek, Martyna). Tak duży rozstrzał wymagał głębszego omówienia zadania.

 Delete Estimates Hide  	
Name	Story Points
Karolina	2
Agnieszka	3
Mateusz	3
Antek	5
Martyna	5
Amile	8

Runda 2

Po wstępnej dyskusji i odrzuceniu skrajnych wartości, zespół zaczął dochodzić do porozumienia. Większość osób (Antek, Mateusz, Martyna, Karolina) zeszła się na ocenie 3 SP. Agnieszka podniosła wycenę do 5 SP, a Amile zredukował z 8 do 5 SP, co pokazało, że część zespołu wciąż widzi potencjalne trudności, np. w konfiguracji chmury.

 Delete Estimates Hide  	
Name	Story Points
Antek	3
Mateusz	3
Martyna	3
Karolina	3
Agnieszka	5
Amile	5

Runda 3

Trzecia runda to wciąż utrzymujący się podział głosów między 3 SP a 5 SP. Mateusz i Antek pozostali przy trójce, natomiast Amile i Agnieszka nadal trzymali się piątki, natomiast Karolina zwiększyła swój głos na 5 SP. Sytuacja ta wymagała ostatecznego doprecyzowania stanu przygotowania danych do treningu.

 Delete Estimates Hide  	
Name	Story Points
Karolina	3
Mateusz	3
Antek	3
Amile	5
Agnieszka	5
Karolina	5

Runda 4

Ostatnia krótka dyskusja rozwiązała wszelkie wątpliwości dotyczące nakładu pracy. Ustalono, że dataset nie będzie wymagał dodatkowej obróbki, co przekonało resztę zespołu do obniżenia wyceny. Wszyscy członkowie zgodnie wybrali 3 Story Points. Ta wartość została przypisana do zadania w backlogu.

 Delete Estimates Hide  	
Name	Story Points
Karolina	3
Antek	3
Martyna	3
Mateusz	3
Amile	3
Agnieszka	3

3 Założenia i dobór zakresu sprintu

Pojemność zespołu i prędkość (Velocity)

Projekt realizowany jest przez 6-osobowy zespół studencki pracujący zdalnie. Każdy członek zespołu przeznacz na projekt średnio **20 godzin na sprint**. Wartość ta stanowi czas netto dostępny na realizację zadań z backlogu - uwzględnia już tzw. *szum*, czyli czas pochłaniany przez aktywności niezwiązane bezpośrednio z wytwarzaniem: spotkania zespołowe, code review, komunikację na Discordzie oraz naukę nowych technologii. Nie

stosujemy oddzielnej kolumny na dni ustawowo wolne – jako studenci nie pracujemy w trybie etatowym i sami zarządzamy swoim czasem w ramach tych 20 godzin.

Prędkość zespołu (velocity) wyznaczono na podstawie historycznych danych z poprzednich iteracji:

- **Sprint 1** (01.03–10.03.2026): zrealizowano ok. **8 SP** – prace inicjalne: konfiguracja repozytorium, wstępny pipeline YOLO+UNet++, research (Issues #1, #2, #3 oraz prace nieewidencjonowane w Issues); pojemność 120 h (6 os. $\times$ 20 h); prędkość = 0,07 SP/h
- **Sprint 2** (11.03–22.03.2026): zrealizowano **9 SP** – implementacja funkcji strat, Mixed Precision Training, automatyzacja adnotacji YOLO, naprawa bugu datasetu (Issues #6, #9, #10, #11); pojemność 120 h; prędkość = 0,08 SP/h
- **Sprint 3** (23.03–13.04.2026): zrealizowano **19 SP** – integracja kamery, dokumentacja projektu kamery, retraining YOLO, pełny pipeline backendowy (Issues #16, #19, #20, #17); pojemność 120 h; prędkość = 0,16 SP/h
- **Sprint 4** (14.04–21.04.2026): zrealizowano **24 SP** – refaktor dokumentacji, testy YOLO, dokumentacja kamery, pasek postępu, rozszerzenie datasetu (Issues #30, #55, #56, #58, #59); pojemność 120 h; prędkość = 0,20 SP/h

Rosnąca prędkość zespołu odzwierciedla krzywą uczenia - wraz z kolejnymi sprintami zespół lepiej estymuje zadania i sprawniej pracuje ze stosem technologicznym. Do szacowania zakresu Sprintu 5 przyjęto prędkość ze Sprintu 4 jako najbardziej aktualną: **0,20 SP/h**.

Dobór zakresu Sprintu 5

Dane wejściowe:

- łączna liczba *story points* w backlogu produktu – **120 SP** (obejmuje zarówno Issues w GitHub, jak i prace nieformalne: badania, prototypowanie sprzętu, konsultacje)
- zakładana liczba sprintów = 6; zakładana średnia prędkość = ok. **20 SP/sprint**
- czas trwania Sprintu 5 – 2 tygodnie (22.04–05.05.2026); ale w trakcie Sprintu odbywa się majówka (prawdopodobnie 1 tydzień efektywnej pracy)

Sprint 4 – realizacja (podstawa do szacowania):

- faktycznie zrealizowany zakres – **24 SP** przy pojemności 120 h
- faktyczna prędkość = **0,20 SP/h**

Sprint 5 – szacowanie:

- pojemność zespołu w Sprincie 5 – 99 h (patrz tabela poniżej – cztery osoby miały ograniczoną dostępność z powodu wyjazdu lub choroby)
- teoretyczny zakres = $99 \text{ h} \times 0,20 \text{ SP/h} \approx 18 \text{ SP}$
- **przyjęty zakres = 20 SP** – wartość nieznacznie wyższa od obliczonej, *stretch goal*, uzasadniony faktem, że Sprint 5 jest jednak dwutygodniowym sprintem i część prac (konfiguracja harmonogramu uczenia, augmentacje) ma charakter dobrze zdefiniowany technicznie

Wybrane elementy z backlogu produktu (łącznie 20 SP):

- Issue #68: Contact doctor for medical advice
- Issue #57: Retrain UNET++ model on expanded dataset
- Issue #65: Add progress steps from backend to UI
- Issue #67: Test different YOLO versions – full report
- Issue #63: Technical documentation refactor
- Issue #45: Implement TTA and fundus-specific augmentations
- Issue #46: Configure Cosine Annealing with Warmup

Uzasadnienie wyboru: Zadania wybrano celowo, aby domknąć etap optymalizacji modeli AI. Bez wdrożenia TTA i Cosine Annealing (Issues #45 i #46) ponowny trening UNet++ (#57) nie przyniósłby optymalnego wzrostu metryki Dice. Zintegrowanie paska postępu w UI (#65) jest kluczowe dla zebrania feedbacku podczas zbliżającej się konsultacji medycznej z okulistą (#68).

Tabela pojemności zespołu

Poniższa tabela przedstawia dostępność poszczególnych członków zespołu w Sprincie 5. Czas bazowy = 20 h/os., wliczając szum. Oddzielnie uwzględniono indywidualne nieobecności.

Członek zespołu	Baza (h)	Nieobecność (h)	Powód	Pozostało (h)
Martyna Borkowska	20	5	Wyjazd na majówkę	15
Karolina Glaza	20	7	Choroba na początku sprintu	13
Mateusz Dobry	20	5	Wyjazd na majówkę	15
Agnieszka Pawłowska	20	0	–	20
Amila Amarasekara	20	4	Wyjazd na majówkę	16
Antoni Naczke	20	0	–	20
Zespół	120	21	–	99

4 Cel sprintu

Cel Sprintu 5 został sformułowany na podstawie wyników retrospektywy Sprintu 4 oraz decyzji podjętych podczas spotkania planistycznego z dnia 21.04.2026. Po zakończeniu poprzedniej iteracji – w której rozszerzono dataset, przetestowano wstępnie różne wersje YOLO i uruchomiono pasek postępu po stronie backendu – zespół zidentyfikował dwa kluczowe braki blokujące dalszy rozwój produktu: brak walidacji medycznej ze strony specjalisty oraz nieoptymalny proces uczenia modelu UNet++.

Dlatego głównym celem tego sprintu jest **dostarczenie zoptymalizowanego i medycznie skonsultowanego pipeline’u detekcji jaskry**, który będzie gotowy do kolejnej rundy testów z udziałem lekarza. Konkretnie oznacza to:

- Ponowny trening UNet++ z zastosowaniem technik TTA i CLAHE, które zespół zdecydował się wdrożyć po analizie słabości dotychczasowej segmentacji tarczy nerwu wzrokowego – model zbyt często błędnie wyznaczał granicę cup/disc przy zdjęciach o niskim kontraście.
- Wdrożenie harmonogramu Cosine Annealing z fazą Warmup, co ustabilizuje oscylacje funkcji straty obserwowane w poprzednich treningach i powinno przełożyć się na lepszą metrykę Dice.
- Przeprowadzenie konsultacji z okulistą (oznaczonej w backlogu jako P-CRITICAL) – planujemy uzyskać zewnętrzną, medyczną ocenę działania aplikacji i wyznaczonych przez nią wartości CDR.
- Domknięcie integracji paska postępu w UI aplikacji iOS, tak aby lekarz podczas konsultacji widział pełny, czytelny przepływ analizy – od wczytania zdjęcia, przez detekcję ROI przez YOLO, aż po wynik segmentacji UNet++.

Najważniejsza wartość dla interesariuszy wynikająca z tego sprintu to możliwość przeprowadzenia pierwszej pełnej, end-to-end demonstracji systemu przed lekarzem-specjalistą. Dotychczas aplikacja działała technicznie poprawnie, ale brakowało zewnętrznej weryfikacji czy wyznaczane wartości CDR są klinicznie wiarygodne i czy interfejs jest intuicyjny w warunkach rzeczywistego badania. Po tym sprincie zespół będzie dysponował zarówno lepszym modelem, jak i konkretnym feedbackiem medycznym – co bezpośrednio przełoży się na kierunek prac w Sprincie 6.

5 Backlog sprintu

Poniżej przedstawiono stan backlogu Sprintu 5 na początku iteracji (22.04.2026), wygenerowany z narzędzia GitHub Projects. Zrzut ekranu tablicy kanban pokazuje wszystkie zaplanowane zadania w momencie startu sprintu. Każdy element backlogu produktu został rozbity przez odpowiedzialnego członka zespołu na konkretne zadania wytwórcze i oszacowany w godzinach – rozbiecie to przedstawia tabela poniżej.

Sprint 5 7 Apr 22 - May 05 Current ...									
18	 MateuszDobry	Todo	Implement TTA and fundus-specific augmentations (C... #45	P-LOW	3	Sprint 5	[EPIC] Se...		
19	 AntNac	Todo	Configure Cosine Annealing with Linear Warmup #46	P-LOW	2	Sprint 5	[EPIC] Se...		
20	 martynkaghe	Todo	Technical documentation refactor #63	P-LOW	5	Sprint 5	[EPIC] Pro...		
21	 kequel	Todo	Add progress steps from backend to UI #65	P-MEDIUM	3	Sprint 5	[EPIC] Int...		
22	 Amila321	Todo	Test diffrent YOLO versions - full raport #67	P-MEDIUM	2	Sprint 5	[EPIC] Pro...		
23	 AntNac and Mateus...	Todo	Retrain UNET++ model on expanded dataset #57	P-HIGH	3	Sprint 5	[EPIC] Se...		
24	 Agnesix	Todo	Contact doctor for medical advice #68	P-CRITICAL	2	Sprint 5	[EPIC] Pro...		


Element backlogu (Issue)	Rozbicie na zadania twórcze	Est.
#57: Retrain UNET++ on expanded dataset (3 SP)	1. Przygotowanie nowego pipeline'u danych 2. Konfiguracja hiperparametrów modelu 3. Uruchomienie treningu na chmurze Azure i monitoring	3h 2h 6h
#65: Add progress steps from backend to UI (5 SP)	1. Wystawienie statusów etapów analizy w FastAPI 2. Odbiór i parsowanie statusów po stronie Swift 3. Implementacja animacji paska postępu (iOS UI)	4h 3h 3h
#45: Implement TTA and fundus augmentations (2 SP)	1. Implementacja funkcji Test-Time Augmentation 2. Implementacja preprocessingu CLAHE 3. Walidacja wpływu augmentacji na metrykę Dice	4h 2h 2h
#46: Configure Cosine Annealing with Warmup (2 SP)	1. Konfiguracja schedulera w kodzie treningowym 2. Weryfikacja stabilności funkcji straty na wykresach	2h 2h
#68: Contact doctor for medical advice (2 SP)	1. Przygotowanie materiałów i pytań do konsultacji 2. Przeprowadzenie wywiadu z okulistą 3. Sporządzenie dokumentu z wnioskami	2h 1.5h 1h
#67: Test YOLO versions – full report (3 SP)	1. Pobranie wag modeli YOLOv8 i YOLOv5 2. Benchmark czasów inferencji i dokładności detekcji ROI 3. Sporządzenie raportu porównawczego	2h 3h 2h
#63: Technical documentation refactor (3 SP)	1. Przepisanie dokumentów do nowego formatu szablonu 2. Aktualizacja diagramów architektury systemu	3h 2h

6 Kryteria akceptacji dla elementów backlogu

Kryteria akceptacji dla każdego zadania zostały uzgodnione przez zespół podczas spotkania planowania Sprintu (21.04.2026) i wpisane bezpośrednio do GitHub Issues przed startem sprintu. Poniżej opisano treść kryteriów dla każdego issue wraz ze zrzutem ekranu potwierdzającym ich wpisanie do narzędzia.


6.1 Issue #68: Konsultacja medyczna z okulistą

Zadanie uznaje się za ukończone, gdy zaplanowano i potwierdzono termin formalnego spotkania ze specjalistą medycznym, przeprowadzono sesję konsultacyjną oraz przygotowano kompleksowy dokument podsumowujący kluczowe wnioski i podjęte decyzje.




6.2 Issue #57: Ponowny trening modelu UNet++

Zadanie uznaje się za ukończone, gdy przygotowano zbiory treningowe i walidacyjne na podstawie rozszerzonego zbioru zdjęć dna oka, pomyślnie przeprowadzono proces trenowania modelu UNet++, osiągnięto współczynnik Dice wyższy niż w poprzedniej wersji oraz zaktualizowano wersję modelu na backendzie.



6.3 Issue #65: Pasek postępu – integracja backendu z UI iOS

Zadanie uznaje się za ukończone, gdy endpoint backendu śledzi etapy analizy (detekcja ROI, segmentacja, obliczanie CDR), w aplikacji iOS zaimplementowano wizualny wskaźnik postępu (Progress Bar), a interfejs użytkownika jest aktualizowany w czasie rzeczywistym na podstawie statusu z backendu.



6.4 Issue #67: Porównanie wersji YOLO – raport

Zadanie uznaje się za ukończone, gdy przygotowano środowisko benchmarkowe do porównania modeli YOLO, oceniono precyzję detekcji ROI tarczy nerwu wzrokowego oraz stworzono kompleksowy raport końcowy z rekomendacją modelu do wdrożenia produkcyjnego.




6.5 Issue #63: Refaktoryzacja dokumentacji technicznej

Zadanie uznaje się za ukończone, gdy dokumenty projektowe zostały przepisane zgodnie z nowym wymaganym formatem oraz zweryfikowano spójność nazewnictwa plików w całym folderze /docs.




6.6 Issue #45: Augmentacje TTA i CLAHE

Zadanie uznaje się za ukończone, gdy zaimplementowano metodę Test-Time Augmentation (TTA) w potoku inferencji, dodano CLAHE oraz regulację jasności do potoku treningowego, a także zweryfikowano, czy augmentacje nie zniekształcają cech klinicznych obrazu.



6.7 Issue #46: Konfiguracja Cosine Annealing z Warmup

Zadanie uznaje się za ukończone, gdy zaimplementowano scheduler CosineAnnealingWarmRestarts w bibliotece PyTorch oraz zweryfikowano poprawność krzywej uczenia (learning rate) w logach treningowych.



7 Definicja ukończenia (Definition of Done)

Standardy jakościowe, które musi spełnić każde pojedyncze zadanie (Issue), aby mogło zostać uznane za zakończone i włączone do głównej gałęzi kodu (main).

- Kod przeszedł Code Review i uzyskał min. 2 zatwierdzenia od innych członków zespołu.
- Pomyślnie przeszły wszystkie aktualne testy CI (GitHub Actions):
 - **Backend CI:**
 - * *Lint*: sprawdzenie składni i poprawności importów w Pythonie (Flake8).
 - * *Integration Test*: automatyczne uruchomienie serwera FastAPI i weryfikacja endpointu `/analyze-glaucoma` (poprawność odpowiedzi JSON dla testowego obrazu JPEG).
 - * *Swift-Backend Sync*: weryfikacja spójności modeli danych (CodingKeys) między aplikacją mobilną a backendem.
 - **AI Pipeline Checks:**
 - * *Linting*: statyczna analiza kodu rurociągu przetwarzania obrazu (składnia i niezdefiniowane nazwy).
 - **Mobile UI Checks:**
 - * *Swift Syntax*: weryfikacja, czy wszystkie pliki projektu mobilnego kompilują się poprawnie (swiftc).
 - * *Lint*: sprawdzenie zgodności kodu Swift ze standardami stylistycznymi.
- Zaktualizowana dokumentacja techniczna, jeśli zadanie naruszało istniejącą architekturę systemu.
- Przetestowanie manualne aplikacji na docelowym urządzeniu z systemem iOS.
- Potwierdzenie spełnienia wszystkich przypisanych do zadania kryteriów akceptacji (Acceptance Criteria), poprzez np. odznaczenie checkboxów.
- Zadanie zostało przesunięte do kolumny Done w GitHub Projects.